

Lista I - MAE0328

Guilherme Navarro N^oUSP: 8943160

Questão 1

Considere a matriz $A = \begin{pmatrix} \alpha_1 & \beta \\ \beta & \alpha_2 \end{pmatrix}$ com $\alpha_1, \alpha_2, \beta \in \mathbb{R}$. Prove a seguinte proposição: Se $\det(A) > 0$, e $\alpha_1, \alpha_2 > 0$ então $x^T A x > 0 \forall x \in \mathbb{R}, x \neq (0, 0)^T$.

Resolução

$$\det(A) = \alpha_1 \alpha_2 - \beta^2 > 0 \Rightarrow \beta^2 < \alpha_1 \alpha_2 \Rightarrow \beta < \sqrt{\alpha_1 \alpha_2} \quad (I) \text{ com } \alpha_1, \alpha_2 > 0$$

Seja $x^T = (x_1 \ x_2)$ e $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ Mostrar que:

$$(x_1 \ x_2) \begin{pmatrix} \alpha_1 & \beta \\ \beta & \alpha_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} > 0$$

Então,

$$(\alpha_1 x_1 + \beta x_2 \ \beta x_1 + \alpha_2 x_2) \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \alpha_1 x_1^2 + \beta x_1 x_2 + \beta x_1 x_2 + \alpha_2 x_2^2 = \alpha_1 x_1^2 + 2\beta x_1 x_2 + \alpha_2 x_2^2 \quad (II)$$

Sabemos que: $\alpha_1 x_1^2 > 0$ e $\alpha_2 x_2^2 > 0$ substituindo β da equação (II) pelo da equação (I), temos que:

$$\alpha_1 x_1^2 + 2\sqrt{\alpha_1 \alpha_2} x_1 x_2 + \alpha_2 x_2^2 \quad (III)$$

Assim, podemos escrever (III) da seguinte forma:

$$(\sqrt{\alpha_1} x_1 + \sqrt{\alpha_2} x_2)^2 > 0 \Rightarrow x^T A x > 0 \quad \blacksquare$$

Questão 2

Os próximos itens são referentes ao método iterativo de Newton-Raphson para $\theta = (\mu, \sigma)$,

$$\begin{pmatrix} \hat{\mu}^{(j+1)} \\ \hat{\sigma}^{(j+1)} \end{pmatrix} = \begin{pmatrix} \hat{\mu}^{(j)} \\ \hat{\sigma}^{(j)} \end{pmatrix} - \begin{pmatrix} \frac{\partial^2 l(\theta, y)}{\partial \mu^2} & \frac{\partial^2 l(\theta, y)}{\partial \mu \partial \sigma} \\ \frac{\partial^2 l(\theta, y)}{\partial \mu \partial \sigma} & \frac{\partial^2 l(\theta, y)}{\partial \sigma^2} \end{pmatrix}_{(\theta = \hat{\theta}^{(j)})}^{-1} \begin{pmatrix} \frac{\partial l(\theta, y)}{\partial \mu} \\ \frac{\partial l(\theta, y)}{\partial \sigma} \end{pmatrix}_{(\theta = \hat{\theta}^{(j)})}, \quad j \in \{1, \dots, n\}$$

(a) Considere o modelo $Y = \mu + e_i$, em que $w_i = \frac{1}{\sigma} e_i \stackrel{iid}{\sim} Cauchy(0, 1)$, $i \in \{1, \dots, n\}$ i.e.

$$f_w(w_i) = \frac{1}{\pi(1 + w_i^2)} \mathbb{I}_R(w_i)$$

Calcule o logaritmo da função de verossimilhança $l(\theta, y)$ e suas primeiras e segundas derivadas.

Resolução

Aplicando o teorema da transformação de variável: $Y = \mu + \sigma w_i \Rightarrow Y^{-1} = \frac{y_i - \mu}{\sigma} \Rightarrow \frac{dY^{-1}}{dw_i} = \frac{1}{\sigma}$ Logo:

$$f_y\left(\frac{y_i - \mu}{\sigma}\right) \left| \frac{1}{\sigma} \right| = f_y\left(\frac{y_i - \mu}{\sigma}\right) \frac{1}{\sigma} = \frac{1}{\pi\sigma(1 + (\frac{y_i - \mu}{\sigma})^2)} \mathbb{I}_R(y_i)$$

Assim $Y_i \sim Cauchy(\mu, \sigma) \Rightarrow f(y_i) = \frac{1}{\pi\sigma[1 + (\frac{y_i - \mu}{\sigma})^2]} = \frac{1}{\pi[\sigma + \frac{(y_i - \mu)^2}{\sigma}]} = \frac{\sigma}{\pi(\sigma^2 + (y_i - \mu)^2)} \mathbb{I}_R(y_i)$ $i \in \{1, \dots, n\}$ com $\sigma > 0$. Logo a sua função de verossimilhança é:

$$L(\theta, y) = \prod_{i=1}^n f(y_i) = \prod_{i=1}^n \frac{\sigma}{\pi(\sigma^2 + (y_i - \mu)^2)} = \left(\frac{\sigma}{\pi}\right)^n \prod_{i=1}^n \frac{1}{\sigma^2 + (y_i - \mu)^2}$$

Aplicando o \ln (logaritmo neperiano) em $L(\theta, y)$. Seja $l(\theta, y) = \ln(L(\theta, y))$

$$l(\theta, y) = n * \ln(\sigma) - n * \ln(\pi) - \sum_{i=1}^n \ln(\sigma^2 + (y_i - \mu)^2)$$

Calculando suas primeiras derivadas:

$$\frac{\partial l(\theta, y)}{\partial \theta} = n \begin{pmatrix} 0 \\ \frac{1}{\sigma} \end{pmatrix} - n * \ln(\pi) \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \sum_{i=1}^n \begin{pmatrix} \frac{-2(y_i - \mu)}{\sigma^2 + (y_i - \mu)^2} \\ \frac{2\sigma}{(\sigma^2 + (y_i - \mu)^2)^2} \end{pmatrix}$$

Agora, calculando suas segundas derivadas:

$$\frac{\partial^2 l(\theta, y)}{\partial \theta^T \partial \theta} = n \begin{pmatrix} 0 & 0 \\ 0 & -\frac{1}{\sigma^2} \end{pmatrix} - n * \ln(\pi) \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} - \sum_{i=1}^n \begin{pmatrix} \frac{-2(y_i - \mu)^2 - \sigma^2}{(\sigma^2 + (y_i - \mu)^2)^2} & \frac{-4\sigma(y_i - \mu)}{(\sigma^2 + (y_i - \mu)^2)^2} \\ \frac{-4\sigma(y_i - \mu)}{(\sigma^2 + (y_i - \mu)^2)^2} & \frac{-(y_i - \mu)^2 - \sigma^2}{(\sigma^2 + (y_i - \mu)^2)^2} \end{pmatrix}$$

(b) Implemente no R o método de Newton-Raphson usando o exercício anterior. Proponha estimativas iniciais para iniciar o processo iterativo e considere como critério de parada do processo iterativo um erro máximo de 10^{-6} .

Resolução

Propondo uma estimativa inicial $\begin{pmatrix} \hat{\mu}^{(0)} \\ \hat{\sigma}^{(0)} \end{pmatrix} = \begin{pmatrix} \text{mediana}(\text{dados}) \\ 1 \end{pmatrix} = \begin{pmatrix} 15.1 \\ 1 \end{pmatrix}$

Obs: Adaptação do algoritmo Newton-Raphson feito pelo professor Patriota na disciplina de Inferência (2º/2018)

```

library(MASS)

dados <- c(17.33,-90.91,18.49,25.03,19.88,18.51,12.39,11.24,11.78,15.15,
          12.24,-238.41,15.19,24.51,11.82,18.16,15.73,11.26,7.41,19.46,
          25.58,-22.27,16.72,17.37,17.42,13.37,12.15,13.75,24.93,34.49,
          21.66,-7.00,16.21,42.07,-2.70,14.91,16.36,14.57,15.11,12.63,
          2.96,13.24,18.68,19.22,30.43,12.87,11.40,-68.39,14.43,13.28,
          3.24,12.63,11.92,22.08,19.47,13.84,20.68,-10.52,12.78,19.03,
          16.65,16.46,2.65,13.55,15.61,59.20,11.46,17.26,18.17,21.50,
          20.31,9.63,13.84,17.94,16.35,18.40,-16.15,17.27,255.83,20.74,
          -1.08,13.67,-5.82,-0.75,21.05,16.70,23.67,11.82,6.23,17.61,
          5.83,19.83,11.14,18.06,12.11,19.83,16.20,11.03,13.99,8.70)

MV = function(x, theta0, epsilon=10^(-6), it=1000){ # Dados, esti. inicial, erro, iterações
  n <- length(x)

  U <- function(t1,t2){ # Primeiras derivadas
    U1 <- 2*sum((x-t1)/(t2^2+(x-t1)^2))
    U2 <- n/t2 - 2*sum(t2/(t2^2 + (x-t1)^2))
    return (c(U1,U2))
  }

  H <- function(t1,t2){ # Segundas derivadas
    H11 <- 2*sum(((x-t1)^2-t2^2)/((x-t1)^2+t2^2)^2)
    H12 <- 4*t2*sum((x-t1)/((x-t1)^2+t2^2)^2)
    H22 <- sum(((x-t1)^2-t2^2)/((x-t1)^2+t2^2)^2) - n/t2^2
    M <- matrix(c(H11,H12,H12,H22),2,2)
    return (M)
  }

  erro <- 10
  j <- 0
  t1 <- numeric () #  $\mu$ 
  t2 <- numeric() #  $\sigma$ 
  t1[1]<-theta0[1] # recebe a estimativa inicial
  t2[1]<-theta0[2] # recebe a estimativa inicial

  while(erro > epsilon & j < it){
    j <- j+1
    Aux <- c(t1[j],t2[j]) - solve(H(t1[j],t2[j]))%*%U(t1[j],t2[j])
    t1[j+1] <- Aux[1]
    t2[j+1] <- Aux[2]
    erro <- max(abs(c(t1[j+1]-t1[j],t2[j+1]-t2[j])))
  }

  S <- list()
  S$erro <- erro
  S$Iteracoes <- j
  S$theta <- c(t1[j+1],t2[j+1])
  S$H <- H(t1[j+1],t2[j+1])
  S$U <- U(t1[j+1],t2[j+1])
  return(S)
}

```

```
#Encontrando as estimativas de MV para o exercício
theta0 <- c(median(dados),1) # Estimativa inicial
fit <- MV(dados,theta0)
```

```
# Estimativas:
fit$theta
```

```
## [1] 15.456148  3.791572
```

```
# Erro
fit$erro
```

```
## [1] 5.580005e-07
```

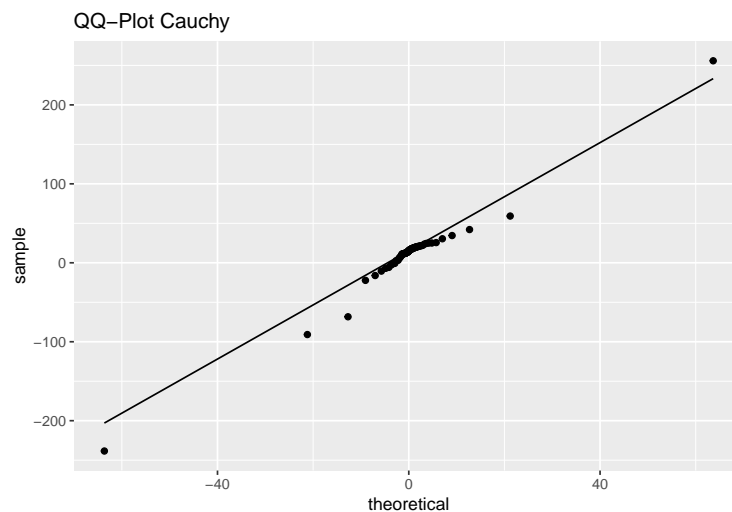
```
# Verificando se os autovalores são negativos
eigen(fit$H) # Autovalores são estritamente negativos -> ponto de máximo
```

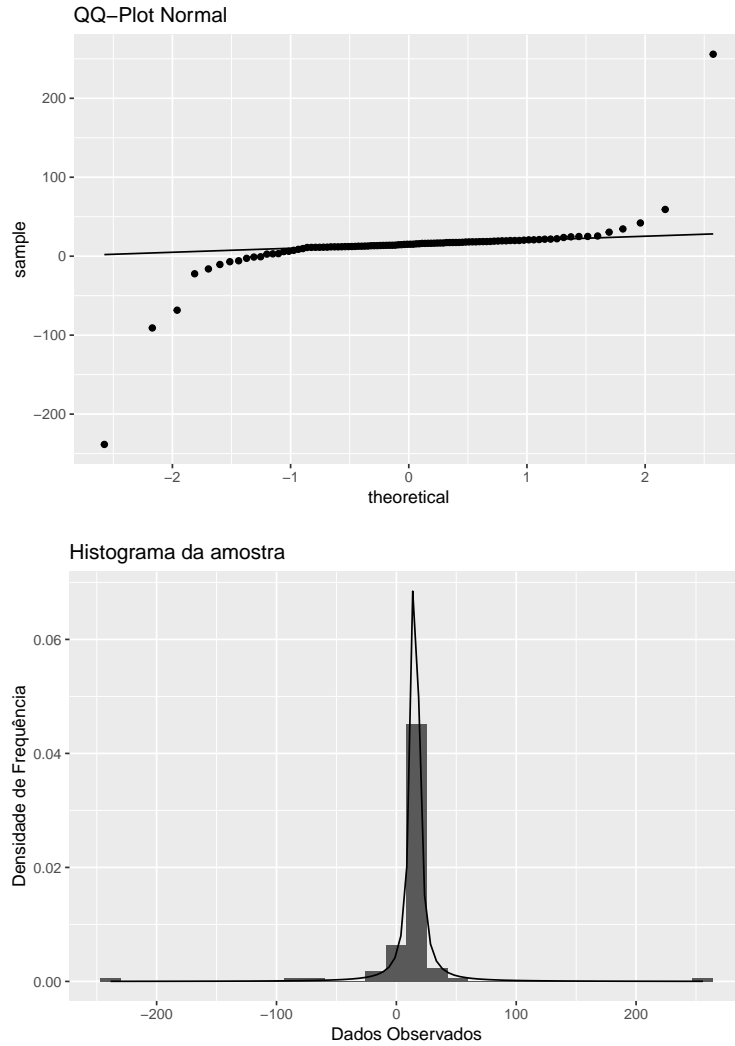
```
## eigen() decomposition
## $values
## [1] -2.949971 -8.432503
##
## $vectors
##          [,1]      [,2]
## [1,] -0.99990942 -0.01345892
## [2,] -0.01345892  0.99990942
```

```
# Estimativas de máxima verossimilhança
t1.hat <- fit$theta[1]
t2.hat <- fit$theta[2]
```

- (c) Justifique o uso de uma distribuição Cauchy para modelagem estatística do conjunto de dados abaixo. Depois, encontre as estimativas de máxima verossimilhança dos parâmetros de localização μ e escala σ^2 .

Resolução





Como temos dados em um range de -238.41 à 255.83, notei que provem de alguma distribuição que tem seu suporte nos \mathbb{R} e como obtive estimativas positivas pensei na distribuição Normal ou Cauchy, através dos gráficos QQ e do histograma com a densidade da distribuição de Cauchy com os parâmetros obtidos através do item 2-b, as estimativas se ajustam muito bem ao histograma da amostra. Assim, com o algoritmo do exercício anterior, temos que:

$$\begin{pmatrix} \hat{\mu}_{mv} \\ \hat{\sigma}_{mv} \end{pmatrix} = \begin{pmatrix} 15.456 \\ 3.791 \end{pmatrix}$$


Questão 3

Considere o conjunto de dados abaixo referente ao uso de vapor (em libras) por uma indústria em função da temperatura média mensal (em graus Fahrenheit).

Temperatura (°F)	Uso de vapor (lb)
21	185.79
24	214.47
32	288.03
47	424.84
50	539.03
68	621.55
74	675.06
62	562.03
50	452.93
41	369.95
30	273.98

- (a) Faça um gráfico de dispersão e justifique o uso de um modelo de regressão linear simples. Formalize tal modelo e suas suposições.

Resolução



O modelo de regressão linear simples se adequa por termos cada observação independente das outras, além disso observando o gráfico de dispersão podemos observar uma tendência linear, para verificar tal observação foi calculado o coeficiente de correlação linear de Pearson entre as variáveis uso de vapor e temperatura que resultou em 0.988, e como está muito próximo de 1 é possível afirmar que há uma forte correlação linear positiva entre as variáveis. Além do mais, para a utilização de tal modelo $Y_i = \beta_0 + \beta_1 x + e_i$ supus que $E(e_i) = 0$ e $Var(e_i) = \sigma^2$ e também homocedasticidade entre os erros.

- (b) Estime β_0 e β_1 pelo método de mínimos quadrados e interprete as estimativas obtidas

Resolução

Como visto em aula os estimadores de mínimos quadrados para β_0 e β_1 são:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$
$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

Onde S_{xy} é a covariância amostral de (x_1, \dots, x_n) e (y_1, \dots, y_n) e S_{xx} é a variância amostral de (x_1, \dots, x_n) , assim as estimativas de mínimos quadrados são:

$$\widehat{\beta}_{0mq} = 418.88 - 9.324 * 45.3636 = -4.09$$

$$\widehat{\beta}_{1mq} = \frac{2926.415}{313.8545} = 9.324$$


Logo temos que a equação do modelo é $Y_i = -4.09 + 9.324x_i$ onde $\widehat{\beta}_{1mq} = 9.324$ pode ser interpretado como o acréscimo esperado de 9.324 lb no uso do vapor quando a temperatura aumenta em 1 °F na média mensal. E $\widehat{\beta}_{0mq} = -4.09$ pode ser interpretado como o valor esperado do uso de vapor onde a temperatura média mensal seja 0 °F, o uso de vapor deveria ser -4.097, entretanto esse valor não faz sentido por ser negativo, para isso foi proposto um deslocamento dos dados de temperatura subtraindo cada valor de sua mediana amostral, assim reajustando o modelo obtemos:

$$Y_i = 434.136 + 9.324 * (x - 47)$$

onde foram mantidas todas as suposições anteriores, assim é possível interpretar $\widehat{\beta}_{0mq} = 434.136$ como sendo o valor esperado de 434.136 lb quando a temperatura é 0 °F.

- (c) Adicione ao gráfico do item (a) a curva de regressão estimada. Qual é a quantidade esperada de vapor a ser utilizada pela indústria em um mês com temperatura média de 70 °F?

Resolução



Usando a equação para prever a quantidade esperada de vapor a ser utilizada pela indústria em um mês com temperatura média de 70 °F: $Y = 434.136 + 9.324 * (70 - 47) \Rightarrow Y = 648.59$. Ou seja, o valor é aproximadamente: 648.59 lb.