

# Lista 2 - MAE0328

Guilherme N<sup>o</sup>USP: 8943160 e Leonardo N<sup>o</sup>USP: 9793436

## Exercício 5

Considere o modelo  $Y = \beta_0 + \beta_1 x_i + e_i$ , em que  $e_i \stackrel{iid}{\sim} \text{Cauchy}(0, 1)$ ,  $i \in \{1, \dots, n\}$  i.e.

$$f(e_i) = \frac{1}{\pi(1 + e_i^2)} \mathbb{I}_R(e_i)$$

- (a) Calcule o logaritmo da função de verossimilhança  $L(\beta, y)$  e suas primeiras e segundas derivadas para o método iterativo de Newton-Raphson.

### Resolução

Aplicando o teorema da transformação de variável:  $Y = \beta_0 + \beta_1 x_i + e_i \Rightarrow Y^{-1} = y_i - (\beta_0 + \beta_1 x_i) \Rightarrow \frac{dY^{-1}}{dy_i} = 1$   
Logo:

$$f(y_i - (\beta_0 + \beta_1 x_i)) = \frac{1}{\pi(1 + (y_i - (\beta_0 + \beta_1 x_i))^2)} \mathbb{I}_R(y_i)$$

Assim temos que se  $e_i \stackrel{iid}{\sim} \text{Cauchy}(0, 1) \Rightarrow Y_i \sim \text{Cauchy}(\beta_0 + \beta_1 x_i, 1)$  Assim, sua verossimilhança é:

$$L(\beta, y) = \prod_{i=1}^n f(y_i) = \prod_{i=1}^n \frac{1}{\pi(1 + (y_i - (\beta_0 + \beta_1 x_i))^2)} = \left(\frac{1}{\pi}\right)^n \prod_{i=1}^n \frac{1}{1 + (y_i - \beta_0 - \beta_1 x_i)^2}$$

Aplicando o  $\ln$ (logaritmo neperiano) em  $L(\beta, y)$ . Seja  $l(\beta, y) = \ln(L(\beta, y))$

$$l(\beta, y) = -n * \ln(\pi) - \sum_{i=1}^n \ln(1 + (y_i - \beta_0 - \beta_1 x_i)^2)$$

Calculando o vetor de suas primeiras derivadas:

$$\frac{\partial l(\beta, y)}{\partial \beta} = -n * \ln(\pi) \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \sum_{i=1}^n \begin{pmatrix} \frac{-2(y_i - \beta_0 - \beta_1 x_i)}{1 + (y_i - \beta_0 - \beta_1 x_i)^2} \\ \frac{2x_i(y_i - \beta_0 - \beta_1 x_i)}{1 + (y_i - \beta_0 - \beta_1 x_i)^2} \end{pmatrix}$$

Agora, calculando o vetor de suas segundas derivadas:

$$\frac{\partial^2 l(\beta, y)}{\partial \beta^T \partial \beta} = -n * \ln(\pi) \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} - \sum_{i=1}^n \begin{pmatrix} \frac{2((y_i - \beta_0 - \beta_1 x_i)^2 - 1)}{(1 + (y_i - \beta_0 - \beta_1 x_i)^2)^2} & \frac{2x_i((y_i - \beta_0 - \beta_1 x_i)^2 - 1)}{(1 + (y_i - \beta_0 - \beta_1 x_i)^2)^2} \\ \frac{2x_i((y_i - \beta_0 - \beta_1 x_i)^2 - 1)}{(1 + (y_i - \beta_0 - \beta_1 x_i)^2)^2} & \frac{2x_i^2((y_i - \beta_0 - \beta_1 x_i)^2 - 1)}{(1 + (y_i - \beta_0 - \beta_1 x_i)^2)^2} \end{pmatrix}$$

- (b) Implemente no R o método de Newton-Raphson usando o exercício anterior. Considere como critério de parada do processo iterativo um erro máximo de  $10^{-6}$

### Resolução

```
# Newton-Raphson
x <- c(18.10, 10.71, 13.43, 11.04, 22.81, 18.71, 6.52, 15.78,
      19.59, 21.18, 15.82, 15.43, 20.61, 16.70, 18.52, 12.75,
      19.61, 14.80, 8.87, 21.82, 21.09, 26.47, 19.18, 23.31,
      15.9, 11.51, 7.09, 12.95, 21.99, 5.75, 15.88, 14.52,
      17.93, 5.19, 12.57, 19.78, 18.96, 14.24, 13.38, 19.38,
      2.47, 12.12, 5.46, 22.37, 22.51, 20.90, 9.92, 19.97,
      18.10, 20.50, 12.98, 21.18, 20.34, 30.71, 6.27, 15.47,
      18.08, 24.60, 7.26, 23.03, 23.67, 24.29, 11.70, 15.21,
      10.00, 10.93, 12.65, 15.70, 20.04, 21.97, 17.63, 10.72,
      19.71, 16.45, 15.04)

y <- c(23.38, 38.07, 29.79, 31.47, 18.44, 32.69, 36.14, 26.18,
      20.58, 18.69, 26.09, 9.27, 19.09, 24.20, 20.82, 29.33,
      19.94, 28.82, 35.16, 21.52, 17.11, 16.17, 22.28, 15.77,
      26.54, 33.40, 50.76, 30.41, 16.43, 35.83, 29.19, 28.16,
      23.34, 43.88, 31.64, 18.41, 21.59, 29.18, 31.34, 26.06,
      46.42, 32.52, 63.93, 15.96, 16.88, 19.55, 35.06, 18.90,
      24.13, 17.46, 30.12, 18.86, 9.10, 2.41, 39.80, 24.73,
      19.67, 13.06, 24.18, 14.01, 15.27, 13.23, 31.12, 27.41,
      70.36, 31.15, 32.10, 25.87, 20.60, 17.28, 24.25, 34.70,
      8.55, 24.48, 27.06)

MV = function(x,theta0,epsilon=10^(-6), it=1000){ # Dados, estimativa inicial, erro, iterações

  U <- function(t1,t2){
    U1 <- 2*sum((-t1-t2*x+y)/(((t2*x-t1+y)^2)+1))
    U2 <- 2*sum((x*(-t2*x-t1+y))/(((t2*x-t1+y)^2)+1))
    return (c(U1,U2))
  }

  H <- function(t1,t2){
    H11 <- 2*sum(((t1-t2*x+y)^2-1)/(((t1-t2*x+y)^2+1)^2)
    H12 <- 2*sum(x*((t1-t2*x+y)^2-1)/(((t1-t2*x+y)^2+1)^2)
    H22 <- 2*sum(x^2*((t1-t2*x+y)^2-1)/(((t1-t2*x+y)^2+1)^2)
    M <- matrix(c(H11,H12,H12,H22),2,2)
    return (M)
  }

  erro <- 10
  j <- 0
  t1 <- numeric()
  t2 <- numeric()
  t1[1]<-theta0[1]
  t2[1]<-theta0[2]

  while(erro > epsilon & j < it){
    j <- j+1
```

```

    Aux <- c(t1[j],t2[j]) - solve(H(t1[j],t2[j]))%*%U(t1[j],t2[j])
    t1[j+1] <- Aux[1]
    t2[j+1] <- Aux[2]
    erro <- max(abs(c(t1[j+1]-t1[j],t2[j+1]-t2[j])))
  }

  S <- list()
  S$erro <- erro
  S$Iteracoes <- j
  S$theta <- c(t1[j+1],t2[j+1])
  S$H <- H(t1[j+1],t2[j+1])
  S$U <- U(t1[j+1],t2[j+1])
  return(S)
}

#Encontrando as estimativas de MV para o exercício
theta0 <- c(52.45,-1.63) # Estimativa inicial
fit <- MV(x,theta0)

# Estimativas:
fit$theta

## [1] 49.96867 -1.49689

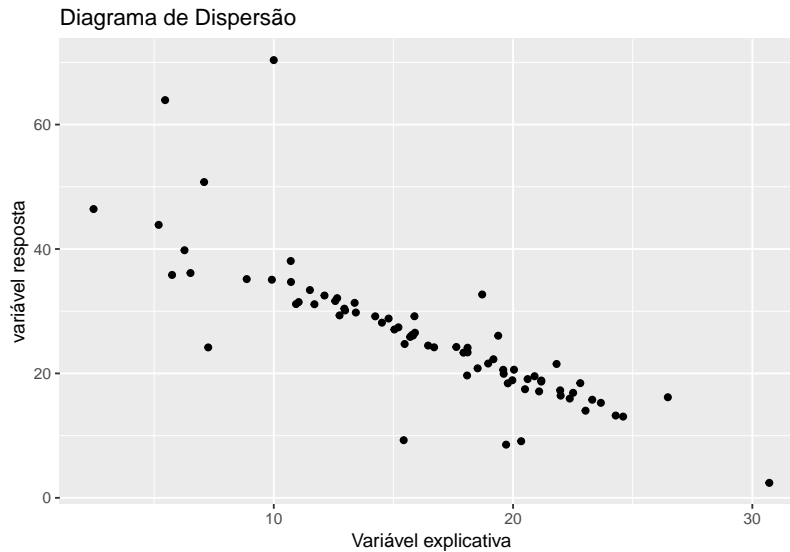
# Verificando se os autovalores são negativos
eigen(fit$H) # Autovalores são estritamente negativos -> ponto de máximo

## eigen() decomposition
## $values
## [1] -3.051852 -11971.936912
##
## $vectors
##          [,1]          [,2]
## [1,] -0.99848558 0.05501398
## [2,] 0.05501398 0.99848558

```

- (c) Usando o conjunto de dados, faça um gráfico de dispersão e proponha estimativas iniciais para  $\beta_0$  e  $\beta_1$ . Encontre as estimativas de máxima verossimilhança do vetor de parâmetros  $\beta$  usando sua função do item (b).

### Resolução




Como podemos notar uma tendencia linear no diagrama de disperção vamos propor as estimativas iniciais de mínimos quadrados onde  $\hat{\beta}_0^{MQ} = 52.454$  e  $\hat{\beta}_1^{MQ} = -1.629$ . Assim pelo algoritmo do exercício anterior temos que as estimativas de máxima verossimilhança são  $\hat{\beta}_0^{MV} = 49.9688$  e  $\hat{\beta}_1^{MV} = -1.4969$

- (d) Compare suas estimativas com a da função *optim()*

### Resolução

No exercício (c) as estimativas de máxima verossimilhança encontradas  $\hat{\beta}_0^{MV} = 49.9688$  e  $\hat{\beta}_1^{MV} = -1.4969$  utilizando o algoritmo de Newton-Raphson com um erro de  $10^{-6}$  ja as estimativas com a função *optim()* geraram as seguintes estimativas  $\hat{\beta}_0^{OP} = 49.9688$  e  $\hat{\beta}_1^{OP} = -1.4969$  onde foram utilizados a o  $-\ln(L(\beta, y))$  como função objetivo para maximização e os método BFGS, Nelder-Mead, L-BFGS-B e SANN notamos que as estimativas coincidiram com a de máxima verossimilhança, para verificação do ajuste, abaixo está o diagrama de disperção com a reta ajustada.



## Exercício 6

O conjunto de dados contém os dados  $x$  : número de sinistros e  $y$  : pagamento total por todos os sinistros (em milhares de coroas suecas).

- (a) Descreva o modelo linear simples que relacione o total pago,  $y_i$ , com número de sinistros,  $x_i$ . Apresente as suposições do modelo e interprete os parâmetros.

### Resolução

O modelo linear simples utilizado é da forma  $Y_i = \beta_0 + \beta_1 x_i + e_i$  supondo  $\mathbb{E}(e_i) = 0$  e  $Var(e_i) = \sigma^2$  e  $e_1, \dots, e_n$  independentes.

Onde  $\beta_0$  representa o valor esperado de  $Y_i$  (total pago de sinistros) quando  $x_i = 0$  (número de sinistros = 0), assim como  $\beta_1$  representa o valor de acréscimo ou decréscimo no valor esperado de  $Y_i$  (total pago de sinistros) quando  $x_i$  (número de sinistros) aumenta em uma unidade.

- (b) Apresente as estimativas de mínimos quadrados de  $\beta_0$  e  $\beta_1$  e a estimativa não viciada para a variância  $\sigma^2$

### Resolução

Utilizando os estimadores de mínimos quadrados obtemos as seguintes estimativas:

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{Cov(x, y)}{Var(x)} = \frac{1861.604}{545.3134} = 3.4138$$

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 * \bar{X} = 98.1873 - 3.4138 * 22.904 = 19.995$$

$$\widehat{\sigma}^2 = \frac{n}{n-2} \sigma_{MV}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i)^2 = \frac{78797.77}{63-2} = \frac{78797.77}{61} = 1291.7486$$

(c) Calcule a matriz de covariâncias estimada para  $\hat{\beta}$ .

### Resolução

A matriz de covariâncias pode ser calculada da seguinte forma:

$$Cov(\hat{\beta}) = \mathbb{E}[(\hat{\beta} - \mathbb{E}(\hat{\beta}))(\hat{\beta} - \mathbb{E}(\hat{\beta}))^T] = Var(\hat{\beta}) = Var((X^T X)^{-1} X^T Y) = \sigma^2 (X^T X)^{-1}$$


Sendo  $\hat{\sigma}^2 = 1291.74986$  e  $(X^T X)^{-1} = \begin{pmatrix} 0.0314 & -0.0007 \\ -0.0007 & 0.00003 \end{pmatrix}$

Assim

$$Cov(\hat{\beta}) = 1291.74986 \begin{pmatrix} 0.0314 & -0.0007 \\ -0.0007 & 0.00003 \end{pmatrix} = \begin{pmatrix} 40.524 & -0.875 \\ -0.875 & 0.382 \end{pmatrix}$$

(d) Faça o gráfico de dispersão e insira a reta estimada:  $\hat{\mu}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$  com  $i = 1, \dots, n$

### Resolução



(d) Calcule o pagamento médio estimado para  $x = 100$  sinistros.



### Resolução

Como nossa equação do modelo é  $\hat{Y}_i = 19.99 + 3.41x_i \Rightarrow \mathbb{E}(Y_i|x_i = 100) = 19.995 + 3.4138 * 100 = 361.375$


## Exercício 7

Considere  $\hat{\beta}_0$ ,  $\hat{\beta}_1$  e  $\hat{\sigma}^2$  obtidos no problema anterior. Simule  $N = 1000$  conjuntos de dados, de tamanho  $n = 63$ , segundo a equação  $Y_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i$ , em que  $x_i$ ,  $i = 1, \dots, 63$ , são dados no exercício anterior e os erros aleatórios devem ser gerados de acordo com  $e_i \stackrel{iid}{\sim} N(0, \hat{\sigma}^2)$  para  $i = 1, \dots, 63$ . Para cada conjunto de dados simulado, estime novamente  $\beta_0$ ,  $\beta_1$  e  $\sigma^2$  e armazene os resultados em uma matriz  $N \times 3$ . Finalmente, apresente os histogramas para os dados armazenados em cada uma das colunas dessa matriz e comente-os.

## Resolução



Assim como mostra a teoria, o resultado simulado ilustra muito bem a normalidade dos dois estimadores seguindo  $\beta_0 \sim N(\beta_0, \sigma^2(\frac{1}{n} + \frac{\bar{x}^2}{nS_{xx}}))$  e  $\beta_1 \sim N(\beta_1, \frac{\sigma^2}{nS_{xx}})$ . Podemos observar também que as estimativas de mínimos quadrados obtidos no exercício anterior são muito parecidos com as estimativas atuais, podemos verificar isso, pois as médias de  $\hat{\beta}_0$  e  $\hat{\beta}_1$  das 1000 estimativas simuladas são de 19.9169 e 3.414197 respectivamente, que coincidem com as estimativas encontradas no item b.



Por sua vez,  $\hat{\sigma}_{MV}^2$  é um estimador viciado, entretanto assintoticamente não viciado, com a correção  $\hat{\sigma}^2 = \frac{n}{n-2} \hat{\sigma}_{MV}^2$  com essa correção temos que  $\hat{\sigma}^2 \sim \chi_{n-2}^2$  como  $n = 63$  possui uma distribuição qui-quadrado com 61 graus de liberdade. Não é possível visualizar o valor estimado no exercício anterior pelo fato de que a distribuição Qui quadrado só depende de seus graus de liberdade.